

Análisis de Datos para Ciberseguridad: Trabajo práctico 2

Alonso Araya Calvo

Pedro Soto

Sofia Oviedo

Instituto Tecnológico de Costa Rica,
Escuela de Ingeniería en Computación,
Programa de Maestría en Ciberseguridad

14 de setiembre de 2025

Escribir la introduccion aqui al final de escribir todo el trabajo...

1. Implementacion de un arbol de decision y random forests para clasificar todos los tipos de ataques

En esta sección se desarrolló la implementación de un árbol de decisión y un random forest para clasificar todos los tipos de ataques encontrados en el dataset KDD99.

Para este efecto se utilizó la librería Scikit Learn que contiene la funcionalidad necesaria para entrenar estos modelos sin tener que implementarlos desde cero. Asimismo, se utilizó la librería Optuna que permite optimizar los hiperparámetros de los modelos fácilmente.

En las siguientes subsecciones se detallan los resultados obtenidos y los pasos realizados para generar estos modelos.

1.1. Generación de las particiones del dataset

Para poder particionar el set de datos correctamente se desarrollo una función llamada 'split_dataset' que se encarga de partir el dataset en tres conjuntos: entrenamiento, validación y prueba.

Para ello se utiliza la función 'train_test_split' de Scikit Learn que permite particionar el dataset en dos conjuntos: entrenamiento y prueba. Despues se utiliza la función 'train_test_split' de Scikit Learn nuevamente para particionar el conjunto de entrenamiento en dos conjuntos: entrenamiento y validación, por medio del calculo del tamaño de la validación respecto al conjunto restante.

Tambien se utilizo la estratificacion para poder garantizar que la distribución de las clases en cada conjunto sea la misma que en el conjunto completo y la habilidad de poder enviar por parametro una semilla para reproducir los resultados.

Esta función 'split_dataset' recibe ciertos parametros que son:

- df: DataFrame de pandas con los datos del dataset
- target_column: Nombre de la columna de las clases en string
- test_size: Proporción numerica del conjunto de prueba
- val_size: Proporción numerica del conjunto de validación
- random_state: Seed para poder reproducir los resultados si se desea

Y lo que finalmente retorna es una tupla con todas las particiones del dataset con la forma (X_train, X_val, X_test, y_train, y_val, y_test).

Esta salida significa:

- X_train: DataFrame con las características de entrenamiento
- X_val: DataFrame con las características de validación
- X_test: DataFrame con las características de prueba
- y_train: Series con las clases de entrenamiento
- y_val: Series con las clases de validación
- y_test: Series con las clases de prueba

El tamaño de cada conjunto se muestra en el Cuadro 1, mostrado a continuación:

Conjunto	Tamaño	Porcentaje
Completo	145586	100 %
Entrenamiento	101910	70 %
Validación	21838	15 %
Prueba	21838	15 %

Cuadro 1: Tamaño del conjunto y particiones de entrenamiento, validación y prueba.

Como se muestra en el Cuadro 1, el conjunto fue particionado correctamente, cumpliendo con el porcentaje esperado.

Para que las particiones fueran uniformes, se utilizo la estratificacion para poder garantizar la distribución uniforme de las clases.

Como es posible observar en el Cuadro 2, la distribucion de clases de manera uniforme hace que se pueda validar de una mejor manera los modelos, ya que se puede ayudar a que el modelo no se entrene con una inclinacion injustificada hacia cierto ataque y los splits sean mas justos para evaluar el modelo en todas sus clases.

Clase	Completo	Entrenamiento	Validación	Prueba
back.	0.006649	0.006653	0.006640	0.006640
buffer_overflow.	0.000206	0.000206	0.000183	0.000229
ftp_write.	0.000055	0.000059	0.000046	0.000046
guess_passwd.	0.000364	0.000363	0.000366	0.000366
imap.	0.000082	0.000079	0.000092	0.000092
ipsweep.	0.004472	0.004465	0.004488	0.004488
land.	0.000131	0.000128	0.000137	0.000137
loadmodule.	0.000062	0.000069	0.000046	0.000046
multihop.	0.000048	0.000049	0.000046	0.000046
neptune.	0.355941	0.355942	0.355939	0.355939
nmap.	0.001085	0.001079	0.001099	0.001099
normal.	0.603300	0.603297	0.603306	0.603306
perl.	0.000021	0.000020	0.000046	0.000000
phf.	0.000027	0.000029	0.000000	0.000046
pod.	0.001415	0.001413	0.001420	0.001420
portsweep.	0.002857	0.002865	0.002839	0.002839
rootkit.	0.000069	0.000069	0.000092	0.000046
satan.	0.006223	0.006221	0.006228	0.006228
smurf.	0.004403	0.004406	0.004396	0.004396
spy.	0.000014	0.000020	0.000000	0.000000
teardrop.	0.006306	0.006300	0.006319	0.006319
warezclient.	0.006134	0.006133	0.006136	0.006136
warezmaster.	0.000137	0.000137	0.000137	0.000137

Cuadro 2: Distribución de clases en los conjuntos: completo, entrenamiento, validación y prueba.

1.2. Entrenamiento, Optimización y Evaluación del Árbol de Decisión

En esta sección se realizó la optimización de los parámetros del árbol de decisión con Optuna. Se compararon los tres mejores árboles de decisión encontrados por Optuna y se evaluaron mediante 10 corridas independientes, generando particiones diferentes para cada corrida y calculando las métricas de evaluación. Finalmente se generó una interpretación en base a los gráficos y tablas generados por los resultados de cada subsección.

1.2.1. Optimización de Hiperparámetros con Optuna

Como parte del trabajo se realizó la optimización de varios hiperparámetros para el árbol de decisión implementado con Scikit Learn. Para este efecto se utilizó la librería Optuna en la cual se optimizaron los parámetros necesarios de la función 'DecisionTreeClassifier' en un estudio de 100 pruebas de optimización, se entrenó con la partición de entrenamiento y se evaluó las predicciones con la partición de validación utilizando como resultado el F1-Score promedio macro en base a la predicción con el

conjunto de validacion.

Para ello se creo la funcion 'optimize_decision_tree' que se encarga de recibir por parametro un objeto de estudio de Optuna por medio de la función 'create_study' y dentro de la funcion de optimizacion se definen los rangos de los parametros a optimizar, se define la funcion de arbol de decision de Scikit Learn y se entrena con la particion de entrenamiento y se evalua con la particion de validacion por medio de las funciones 'predict', 'fit' y para generar la puntuacion se utilizo 'f1_score' de Scikit Learn que tambien es utilizada como salida de la funcion de optimizacion.

Se optimizaron los siguientes hiperparametros:

- Profundidad maxima del arbol (max_depth)
- Cantidad minima de observaciones por particion (min_samples_split)
- Cantidad minima de observaciones por hoja (min_samples_leaf)
- Criterio de pureza (criterion)

Para el parametro de profundidad maxima del arbol se optimizo el valor en un rango de 3 a 20. Este rango se escogio debido a las siguientes razones encontradas [1, 2, 3]:

- Valores muy bajos podrian causar que el arbol no capturen los patrones del dataset correctamente y no genere un buen resultado, por lo que empezar con 3 es un buen valor inicial.
- Valores muy altos podrian permitir que el arbol se sobreajuste y no generalice bien, por lo que 20 es un valor optimo.
- El valor limite de 20 es suficiente ya que mas profundidad no se observa que mejoren el resultado y seria un desperdicio de computo.
- El dataset tiene clases desbalanceadas, por lo que profundidades muy altas podrian crear una inclinacion hacia estas clases grandes.

En cuanto al parametro de cantidad minima de observaciones por particion se optimizo el valor en un rango de 2 a 50. Las consideraciones fueron [4, 5]:

- Los balores muy bajos como 2 podrian generar que el arbol se divida excesivamente y que se ajusta al ruido del dataset.
- Se deja el limite en 50 dado que valores bajos dan paso a mas varianza y posibles sobreajustes, mientras que los valores altos podrian permitir una mejor generalizacion, sin llegar al exceso que el arbol casi no se divida.
- El rango de de 2 a 50 es lo suficientemente moderado para poder generar splits con buen soporte, pero tampoco tan pequeño como para que se generen splits debiles como serian con un valor bajo, evitando un arbol muy simple o especifico.

En el caso de la cantidad minima de observaciones por hoja se optimizo el valor en un rango de 1 a 25. Los puntos a tomar fueron [6, 7]:

- Valores bajos pueden crear hojas con muy pocos ejemplos, dando paso a que se sobreajuste a ciertos patrones específicos del dataset.
- Los valores altos podrían dar paso a poder generalizar mejor, ya que contiene un número más alto de muestras, reduciendo la varianza y posiblemente evitando el sobreajuste.
- Si se obtienen hojas con más datos es posible que los patrones aprendidos sean más estables.
- El valor límite de 25 permite suficientes hojas y reducir los nodos del árbol que podría mantener el árbol más pequeño y eficiente.

Por último, se optimizó el criterio de pureza en un rango de 'gini' y 'entropy'. El criterio para este rango fue [8, 9]:

- Se utiliza solo gini o entropy y no se incluye 'log_loss' debido a que es más costoso computacionalmente y puede no dar una mejora significativa en contraste con los otros dos.
- Se incluye gini ya que es un algoritmo robusto y rápido computacionalmente.
- En el caso de entropy este es un poco más costoso que gini dado a que realiza el cálculo de logaritmos, pero puede llegar a ser un poco más preciso.

Para poder ejecutar esta función se creó un estudio de Optuna con la dirección de maximizar la función objetivo, en este caso al escogerse como métrica el F1-Score promedio macro se buscó mejorar esta puntuación en todos los estudios.

Se realizaron 100 pruebas de Optuna, suficientes para poder encontrar las mejores tres arquitecturas en un tiempo adecuado, su duración de ejecución en Google Colab fue de alrededor de un poco más de dos minutos, mayores números de pruebas realmente no lo mejoraron significativamente por lo que no se justifica la computación y tiempo mayor de estudio.

Se utilizó el F1-Score macro como la métrica a maximizar, debido a que el dataset KDD99 tiene clases desbalanceadas, por lo que esta métrica permite dar importancia a todas las clases y no solo a algunas que son muy representativas en este conjunto. Otras métricas como el accuracy podrían creer que es un buen modelo para cierto tipo de ataques pero podría estar sesgado y otras clases podrían no ser detectadas correctamente con un rendimiento pobre.

Resultados y Demostración del Proceso de Optimización Para documentar el proceso de optimización se generaron distintos gráficos y tablas que permiten observar la evolución de cada estudio realizado y la evolución de los parámetros, en especial de la métrica maximizada que fue el F1-Score, estos gráficos fueron provistos por la librería Optuna por medio de su módulo `optuna.visualization`.

Los datos de los resultados finales se muestran en el Cuadro 3, 4 y 5, mostrado a continuación:

En el Cuadro 3 se observa como para 100 corridas de Optuna se obtuvo un mejor F1-Score de 0.8092, siendo este un buen resultado al ser cercano al 1. Ejecuciones más

Métrica	Valor
Número total de trials	100
Mejor F1-macro	0.8092

Cuadro 3: Resumen de la optimización con Optuna

largas mostraron resultados similares por lo que se justifica el uso de 100 corridas para ahorrar computo y tiempo.

Hiperparámetro	Valor
max_depth	17
min_samples_split	7
min_samples_leaf	1
criterion	gini

Cuadro 4: Mejores hiperparámetros (según el mejor F1-macro)

En el Cuadro 4 podemos determinar que los rangos utilizados para los parametros tienen sentido, dado que finalmente el max_depth se obtuvo un valor de 17, siendo este un valor alto pero no llegando al limite de 20. El min_samples_split se obtuvo un valor de 7, siendo este un valor medio en el rango utilizado. El min_samples_leaf se obtuvo un valor de 1 utilizando el minimo valor del rango. El criterion finalmente se utilizo gini como el mejor criterio, siendo este rapido y adecuado para la tarea.

Arquitectura	F1-macro	max_depth	min_samples_split	min_samples_leaf	criterion
1	0.8092	17	7	1	gini
2	0.7877	13	11	1	gini
3	0.7877	13	11	1	gini

Cuadro 5: Tres mejores arquitecturas encontradas

En el Cuadro 5 se muestran las tres mejores arquitecturas para el estudio realizado. Se observa que el criterio de gini es el mas determinante para este problema, asi como el min_samples_leaf con su valor de 1. Ademas se observa que el valor de max_depth y min_samples_split son similares pero tienden a variar un poco entre los modelos.

Métrica	Valor
F1-score promedio	0.6495
Desviación estándar	0.0975
F1-score mínimo	0.2717
F1-score máximo	0.8092

Cuadro 6: Estadísticas de la optimización

En cuanto al Cuadro 6 se muestran las estadísticas de la optimización en cuando al F1-Score. Donde se observa su promedio, desviación estándar, mínimo y máximo, siendo el máximo el mejor valor encontrado.

Para mostrar los resultados de la evolucion de la optimizacion se generaron distintos graficos mostrados en la Figuras 1, 2, 3 y 4, que serian la historia de optimizacion del F1-Score, importancia de los hiperparametros, relaciones entre parametros, distribuciones de los valores objetivo y una comparacion de las tres mejores arquitecturas por F1-Score.




Figura 1: Historia de optimizacion del F1-Score

En la Figura 1 se explica la evolucion de la metrica objetivo que fue el F1-Score a lo largo de las 100 corridas. Se puede apreciar la tendencia a la alza de la mejor puntuacion pero tambien se observa las variaciones en el la metrica de forma muy dispersa a lo largo de las pruebas. La mejor puntuacion fue encontrada en la corrida 89, la cual fue la que genero el mejor F1-Score de 0.8092, las otras dos mejores fueron encontradas alrededor de las pruebas entre 40 y 50.




Figura 2: Importancia de los hiperparametros

En la Figura 2 se retrata cuales fueron los hiperparametros que tuvieron mas incidencia para contribuir con la mejora de la metrica objetivo. En este caso como podemos observar la profundidad maxima tiene una importancia mucho mas grande que las demas. En este orden se dice que el parametro mas importante es el max_depth, seguido por el min_samples_leaf, el min_samples_split y el criterion.




Figura 3: Relaciones entre hiperparametros y la metrica objetivo

En la Figura 3 se muestran como los hiperparametros optimizados interactuan entre si para generar el mejor F1-Score. En esta grafica podemos ver la tendencia de cada uno de los parametros a cambiar su valor dentro del rango utilizado lo largo de las pruebas. Se puede observar como alguna de estas tienden a quedarse en cierto grupo de valores, en el caso de Gini, se ve como se utiliza mas que el valor de Entropy, asi como min.-

`samples_leaf` y `min_samples_split` tienden a quedarse en valores del lado medio-bajo y finalmente el `max_depth` tiende a utilizar valores altos.

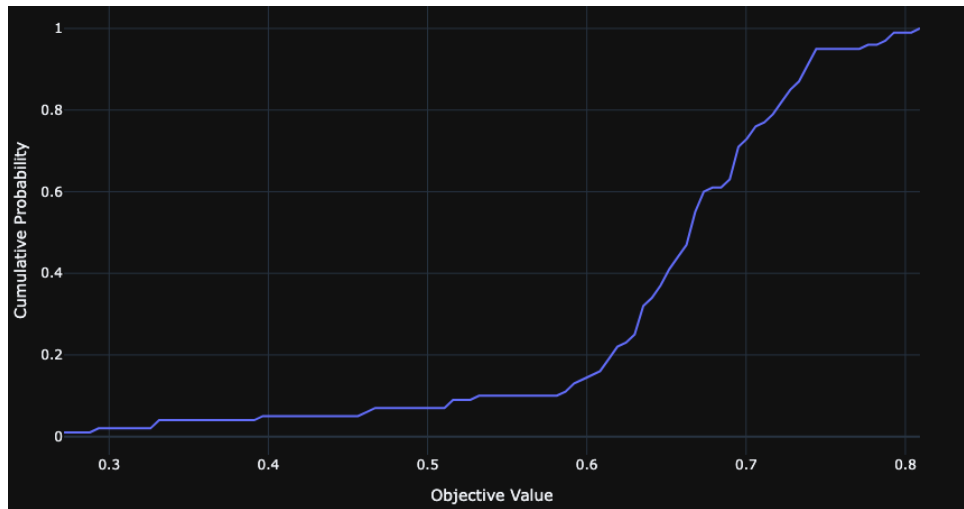


Figura 4: Distribucion del valor objetivo

La Figura 4 es una grafica de distribucion del valor objetivo que fue el F1-Score, se observa que la puntuacion estuvo en un rango entre alrededor de 0.3 y 0.8, siendo el 0.8 el mejor valor encontrado. Ademas de eso se aprecia como la mayoría de pruebas tuvieron una puntuacion entre 0.6 y 0.8, dando como resultado que con Optuna se encontraron buenos resultados en la mayoría de pruebas.




Figura 5: Coordenadas paralelas: relación entre hiperparámetros y F1-macro

En la Figura 5 se observa que las mejores corridas por F1-macro (0.79 - 0.81) se concentran en combinaciones con `max_depth` alto (13 - 17), `min_samples_leaf` de 1, `min_samples_split` (7 - 12) y `criterion` de gini. Esto sugiere que el modelo se beneficia de árboles relativamente profundos con hojas pequeñas, regulados por un umbral de división moderado. Al aumentar `min_samples_leaf` por encima de 1 o al reducir mucho la profundidad, el desempeño tiende a degradarse. Asimismo, gini domina sobre en-

tropy en este problema, consistente con los tres mejores resultados encontrados del Cuadro 5.

1.2.2. Comparacion de las mejores arquitecturas con particiones diferentes

En esta seccion se comparan las tres mejores arquitecturas que se muestran en el Cuadro 5 y se evaluan mediante 10 corridas independientes, generando particiones diferentes para cada corrida manteniendo la proporcion definida en la funcion 'split.-dataset' y calculando diferentes metricas como el F1-Score, accuracy y tasa de falsos positivos para todas las evaluaciones. Finalmente se recopilieron todos los resultados, y se calculo las medias y desviaciones estandar de cada una de las arquitecturas y sus corridas.

Para poder lograr el objetivo de esta seccion se guardaron los resultados de las tres mejores arquitecturas en una lista para su uso posterior, este contenia los parametros, posicion y F1-Score de cada una de las arquitecturas. Despues se definio la funcion 'evaluate_dt_architecture_multiple_runs' la cual va estar encargada de:

- Recibir los parametros de la arquitectura a evaluar necesarias para la funcion 'DecisionTreeClassifier' de Scikit Learn asi como el numero de corridas a realizar por arquitectura y semillas si es necesario para reproducibilidad.
- Se itera sobre el numero de corridas y se generan las nuevas particiones por medio de la funcion 'split_dataset'
- Se entrena el arbol de decision con los parametros recibidos y las nuevas particiones
- Se generan las predicciones por medio de la particion de prueba
- Se evalua y se obtiene el F1-Score Macro, F1-Score por clase, accuracy y tasa de falsos positivos para todas las evaluaciones, siendo estos guardados en una lista individualmente
- Se retorna un diccionario con los resultados de las metricas calculadas como numero de corridas, parametros, todos los F1-Score, accuracy, tasa de falsos positivos y matriz de confusion, ademas de las estadisticas como promedio y desviaciones de las metricas generadas.

Las metricas fueron calculadas mediante las funciones de Scikit Learn 'f1_score', 'accuracy_score', 'precision_recall_fscore_support' y 'confusion_matrix'.

Para el calculo de la tasa de falsos positivos se utilizo la formula:

$$FPR = \frac{FP}{FP + TN} \quad (1)$$

Donde FP es el numero de falsos positivos y TN es el numero de verdaderos negativos. Se utilizo la funcion 'confusion_matrix' de Scikit Learn para obtener la matriz de confusion y calcular los valores de FP y TN.

En los siguientes Cuadros 7, 8 y 9, se muestran las corridas realizadas y sus metricas.

Corrida	F1	Accuracy	FPR
1	0.7639	0.9988	0.0001
2	0.7294	0.9982	0.0001
3	0.7188	0.9982	0.0001
4	0.6905	0.9980	0.0002
5	0.7014	0.9981	0.0002
6	0.7413	0.9983	0.0001
7	0.7452	0.9982	0.0001
8	0.7432	0.9985	0.0001
9	0.8402	0.9984	0.0001
10	0.6797	0.9981	0.0002

Cuadro 7: Resultados – Arquitectura 1

El Cuadro 7 exhibe como la Arquitectura 1 que era la que obtuvo la mejor puntuación, sigue mejorando un poco mas con estas particiones realizadas, inclusive llegando a obtener un F1-Score de 0.8402, siendo este un mejor resultado al inicial con Optuna que se obtuvo de 0.8092.

Corrida	F1	Accuracy	FPR
1	0.7200	0.9979	0.0002
2	0.7110	0.9978	0.0002
3	0.6552	0.9972	0.0003
4	0.6768	0.9978	0.0002
5	0.6416	0.9981	0.0002
6	0.6390	0.9976	0.0002
7	0.6400	0.9978	0.0002
8	0.6782	0.9977	0.0002
9	0.6988	0.9976	0.0002
10	0.7262	0.9978	0.0002

Cuadro 8: Resultados – Arquitectura 2

Corrida	F1	Accuracy	FPR
1	0.6737	0.9976	0.0002
2	0.6167	0.9974	0.0003
3	0.6483	0.9975	0.0002
4	0.7159	0.9974	0.0002
5	0.7049	0.9977	0.0002
6	0.6719	0.9973	0.0002
7	0.7013	0.9977	0.0002
8	0.6717	0.9972	0.0003
9	0.6704	0.9977	0.0002
10	0.6486	0.9970	0.0003

Cuadro 9: Resultados – Arquitectura 3

En cuanto al Cuadro 8 y 9 al ser arquitecturas encontradas con configuracion iden- tica se tienen resultados similares, en este caso a diferencia de la primera arquitectura no se mejoro su F1-Score inicial de 0.7877.

En general todas las particiones obtuvieron metricas buenas inclusive en casi todos los falsos positivos tienen valores muy bajos y los F1-Score por clase tambien estan cerca de 1, dando a entender que es posible que obtengan pocas falsas detecciones y puedan clasificar en su mayoria correctamente las clases.

Para generar un resumen de todos los resultados y calcular las medias y desviacio- nes estandar de las metricas se genero una logica en el notebook la cual esta encargada de utilizar todos los resultados guardados previamente de la funcion 'evaluate_dt_ar- chitecture_multiple_runs' que contiene una lista de los resultados de todas las evalua- ciones, conteniendo los momentos estadisticos de cada una de las metricas utilizadas para cada corrida por arquitectura, asi como los parametros utilizados para cada co- rrida. Siguientemente la logica genera una tabla y unos graficos para visualizaion de la distribucion y valores de las medias, ademas de la desviacion estandaar para cada arquitectura y sus corridas para una mejor comparacion.

Arquitectura	F1-macro Media	F1-macro Desviación Estandar	FPR Media	FPR Desviación Estandar
#1	0.7353	0.0431	0.0001	0.0000
#2	0.6787	0.0323	0.0002	0.0000
#3	0.6723	0.0284	0.0002	0.0000

Cuadro 10: Resultados de las Corridas con Particiones Diferentes




Figura 6: Comparacion de las Arquitectura con Particiones Diferentes

En el Cuadro 10 y la Figura 6 se muestran los resultados generales por arquitectura para todas las 10 corridas realizadas para cada una. En esta se reporta la media y des- viacion para las metricas que se utilizaron de F1-Score macro y tasa de falsos positivos.

En base al Cuadro 10 y la Figura 6 se pueden generar varias conclusiones de acuer- do a las arquitecturas encontradas:

- La Arquitectura 1 es la que obtiene el mejor F1-Score macro y tasa de falsos posi- tivos. Por ende sigue demostrando que es la mejor arquitectura en comparacion a las arquitecturas 2 y 3.
- La Arquitectura 2 y 3 al tener los mismos parametros son similares pero tienen una menor desviacion en sus resultados dando a entender que son un poco mas estables en sus resultados, la arquitectura 1 es mas dispersa.

- Todas las arquitecturas presentan una tasa de falsos positivos muy baja, siendo este un buen resultado para el problema de detección de intrusos, ya que un aspecto importante es que se tengan pocas falsas detecciones y un sistema de este tipo sea más robusto.

1.3. Entrenamiento, Optimización y Evaluación de un Random Forest

En esta sección se realizó la optimización del parámetro `n_estimators` del Random Forest con Optuna, este parámetro corresponde al número de árboles del Random Forest. Se compararon los dos mejores Random Forests encontrados por Optuna y se evaluaron mediante 10 corridas independientes, generando particiones diferentes para cada corrida y calculando las métricas correspondientes, así como una interpretación final de todos los resultados generados.

1.3.1. Optimización de Hiperparámetros con Optuna

Similar a la sección 1.2 se realizó la optimización de los parámetros con Optuna, pero esta vez solamente optimizando un Random Forest por medio de la función `'RandomForestClassifier'` de Scikit Learn. Esto fue realizado en la función `'optimize_random_forest'` que se encarga de recibir por parámetro un objeto de estudio de Optuna por medio de la función `'create_study'` y dentro de la función de optimización se definió el único parámetro a optimizar que es el `n_estimators`, este parámetro indica la cantidad de árboles del Random Forest. Además, se entrenó con la partición de entrenamiento y se evaluó con la partición de validación, finalmente se utilizó el F1-Score macro como la métrica a maximizar y este era el valor que retornaba la función de optimización.

Se optimizó mediante el la métrica de F1-Score macro, debido a las clases desbalanceadas del dataset KDD99, esto permitía poder realizar un promedio sin considerar la frecuencia de las clases y poder dar una mejor perspectiva del rendimiento general del modelo. Otras métricas podrían tener problemas en cuanto a sesgo de las clases y pensar que es un buen modelo sin tomar en cuenta otras clases minoritarias y generando posiblemente un modelo con muchas falsas alarmas.

Se realizaron 50 pruebas de optimización debido al alto tiempo de ejecución y cómputo, en nuestros experimentos se observó que la mayoría de veces se obtenía el mejor resultado en corridas tempranas usualmente antes de la corrida 20, por lo que utilizar más pruebas no se consideró necesario para efecto del trabajo, tomando como balance la computación y tiempo de corrida. En nuestra ejecución en Google Colab el tiempo para ejecutar estos trials es de alrededor de siete minutos y medio.

Se optimizó el parámetro `n_estimators` en un rango de 10 a 300, este rango se escogió debido a que se observó que:

- Utilizar pocos árboles el rendimiento es muy similar a utilizar un solo árbol, por lo que se puede considerar que 10 árboles es un buen valor inicial.
- En varios experimentos realizados la mejor solución se encontró en menos de 100 `n_estimators`, por lo que se podría considerar que 300 es un valor suficiente para

experimentar, esto tambien es apoyado por [10] donde menciona que en general hay rendimientos decrecientes despues de 200 a 500 arboles.

- El costo computacional podria aumentar si se utilizan demasiados arboles y el rendimiento podria no mejorar en relacion con el costo y tiempo computacional.

Resultados y Demostración del Proceso de Optimizacion Similar a los arboles de decision se generaron graficos y tablas para visualizar la evolucion de la optimizacion. Estos graficos tambien fueron provistos por la libreria Optuna por medio de su modulo `optuna.visualization`.

Como resultado del proceso de optimizacion se encontro el mejor parametro `n_estimators` y F1-Score macro. Esto se muestra en el siguiente Cuadro 11:

	Total de trials	Mejor F1-macro	<i>n_estimators</i> óptimo
Resultados	50	0.7779	61

Cuadro 11: Resumen de la optimización de Random Forest con Optuna

Del Cuadro 11 se muestra un resultado optimo de 0.7779 en F1-Score macro, siendo este un buen resultado al ser mas cercano al 1 y un numero de arboles moderado para el rango utilizado previamente que podia llegar hasta 300.

Tambien, se calcularon las dos mejores arquitecturas que se muestran en el Cuadro 12:

Modelo	F1-macro	<i>n_estimators</i>
Random Forest #1	0.7779	61
Random Forest #2	0.7779	66

Cuadro 12: Top 2 modelos de Random Forest encontrados

Del cuadro 12 observamos que las dos arquitecturas obtuvieron el mismo F1-Score macro y un numero de arboles muy similar.

En base a las siguientes figuras generadas sobre la evolucion de la optimizacion se puede apreciar una mejor perspectiva del proceso.




Figura 7: Historico de Optimizacion del Random Forest

En la Figura 7 se denota como mejoro el valor objetivo que fue nuestro F1-Score macro a lo largo de los estudios. Se muestra como muy rapidamente desde menos de 10 trials se obtuvo el mejor resultado de las 50 pruebas, tambien a lo largo de los trials se observan distintos puntos donde el F1-Score llego a un punto similar en multiples pruebas, lo que podria indicar que no es posible realmente mejorar por mucho el modelo por mas trials que se hagan para el rango de `n_estimators` utilizado. Ademas, se observa como en general el RandomForest provee moderadamente buenos resultados, ya que la mayoria de pruebas obtuvieron un F1-Score macro entre 0.76 y 0.77.




Figura 8: Relacion entre hiperparámetros y F1-macro

En esta Figura 8 se encuentra con el mejor optimo entre alrededor de 40 a 80 arboles, indicando que para el numero de pruebas realizadas no es necesario utilizar muchos mas arboles para obtener un mejor rendimiento, ya que los rangos mayores al 80 se estancan en valores similares o menores, lo que no justificarian un numero alto de arboles debido al costo computacional y tiempo de entrenamiento, inclusive al utilizar un numero de arboles altos como se ve en algunas de estas pruebas de 200+ no se observa una mejora significativa.




Figura 9: Distribucion del Valor Objetivo

De la Figura 9 se muestra que un aproximado del 75 % de las configuraciones de $n_estimators$ obtuvieron un F1-Score macro entre 0.76 y 0.77, y solo una prueba obtuvo un F1-Score macro de 0.7779, en general las puntuaciones fueron bastante similares y hasta existe un punto plano en el que el valor se mantiene constante hasta llegar al valor maximo.

Métrica	Valor
F1-score promedio	0.7708
Desviación estándar	0.0042
F1-score mínimo	0.7661
F1-score máximo	0.7779

Cuadro 13: Estadísticas de la optimización de Random Forest

Finalmente en el Cuadro 13 podemos ver los momentos estadísticos de la optimización de Random Forest, donde se observa el promedio del F1-Score siendo un valor moderadamente alto debido a que fueron muy similar en las corridas, una desviación estándar moderada debido a que no existe mucha dispersión en las puntuaciones y esto es soportado por los máximos y mínimos donde se ve que no fueron valores muy distantes.

1.3.2. Comparacion de los dos mejores Random Forests con particiones diferentes

Simular a la implementacion de arboles de decision, en esta parte se compararon solamente dos arquitecturas de RandomForest que fueron encontradas despues de 50 pruebas optimizando la cantidad de arboles con Optuna, estas se puede observar en el Cuadro 12.

Para efectos de esta tarea se genero una funcion llamada 'evaluate_rf_architecture.-multiple_runs' que se encarga de recibir los parametros guardados anteriormente de los RandomForests encontrados, el numero de corridas a realizar y una lista de seeds aleatorias para reproducir los experimentos.

Esta funcion itera sobre el numero de corridas, se generan nuevas particiones mediante la funcion 'split_dataset' realizada en la primera parte y se extrae los conjuntos de entrenamieto y prueba, se entrena el RandomForest con los parametros recibidos y se generan las predicciones con el conjunto de prueba, se calculan las metricas de F1-Score macro, F1-Score por clase, accuracy, tasa de falsos positivos, precision y recall por clase, ademas de la matriz de confusion, todos los resultados fueron recopilados, se generaron momentos estadisticos para las metricas y fueron guardados en una variable para uso posterior en las siguientes celdas.

Esta funcion se ejecuto para las dos arquitecturas y se encontraron los siguientes resultados en el Cuadro 14 y 15:

Corrida	F1-macro	Accuracy	FPR
1	0.8266	0.9991	0.0001
2	0.8361	0.9994	0.0001
3	0.7790	0.9995	0.0000
4	0.7570	0.9991	0.0001
5	0.7698	0.9994	0.0001
6	0.8057	0.9991	0.0001
7	0.7323	0.9989	0.0001
8	0.7655	0.9990	0.0001
9	0.8443	0.9993	0.0001
10	0.8820	0.9994	0.0001

Cuadro 14: Resultados por corrida del Random Forest #1 (n_estimators = 61)

Como se observa en los Cuadros 14 y 15 se obtuvieron resultados muy similares para las dos arquitecturas. En este caso se observa que el F1-Macro aumento considerablemente respecto al mejor F1-Score macro obtenido en el proceso de optimizacion, como se puede leer, el mejor F1-Score macro fue de 0.7779 y ahora con estas particiones diferentes se obtuvieron valores entre 0.82 y 0.88, esto es un aumento considerable respecto a lo inicial. Ademas de esto, en ambas arquitecturas se observan valores de accuracy de 0.99+ indicando una buena capacidad de clasificar correctamente las clases y una tasa de falsos positivos muy baja, indicando que el modelo podria no tener muchas falsas alarmas, perfecto para un sistema de deteccion de intrusos.

En el caso de esta comparacion podemos ver que el mejor F1-Score macro fue el de la Arquitectura 2, con un F1-Score macro de 0.8865 y una tasa de falsos positivos de 0. Sin embargo, podemos ver que la Arquitectura 1 es mas estable ya que el rango de su

Corrida	F1-macro	Accuracy	FPR
1	0.8865	0.9995	0.0000
2	0.6743	0.9992	0.0001
3	0.6932	0.9991	0.0001
4	0.8408	0.9992	0.0001
5	0.8618	0.9990	0.0001
6	0.8302	0.9994	0.0001
7	0.8782	0.9995	0.0000
8	0.7747	0.9991	0.0001
9	0.6997	0.9990	0.0001
10	0.7704	0.9992	0.0001

Cuadro 15: Resultados por corrida del Random Forest #2 (n_estimators = 66)

F1-Score es menos variable entre corridas, el de la Arquitectura 2 es mas variable y sus valores por ende son mas dispersos, por lo que la Arquitectura 1 es mas consistente y confiable.

Otro punto a recalcar es que ambos usaron una cantidad de estimadores similares de 61 y 66, y tienen una variabilidad moderada en sus resultados por lo que indica que este parametro tiene un nivel de impacto a considerar.

Random Forest	n_estimators	F1-macro Media	F1-macro Desv Std	Accuracy Media	Accuracy Desv Std	FPR Media	FPR Desv Std
#1	61	0.7998	0.0444	0.9992	0.0002	0.0001	0.0000
#2	66	0.7910	0.0761	0.9992	0.0002	0.0001	0.0000

Cuadro 16: Resumen de evaluación de los mejores Random Forests

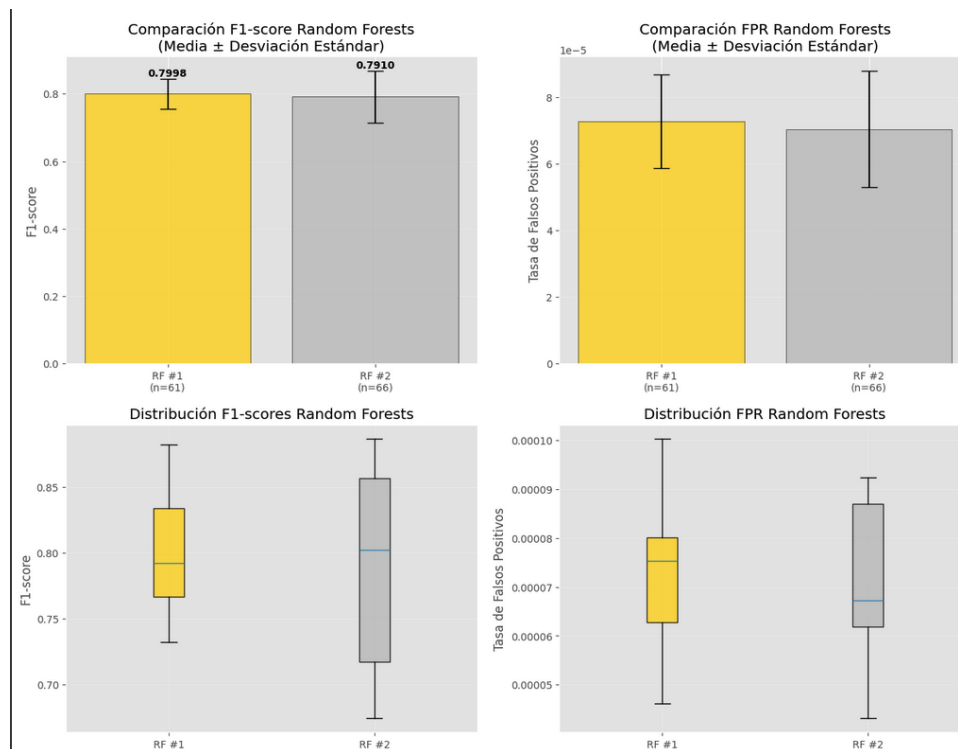


Figura 10: Comparacion de los dos mejores Random Forests

En el Cuadro 16 y la Figura 10 podemos ver una comparacion de las estadisticas de los resultados de la corrida de las particiones por cada arquitectura, esto recalca los comentarios anteriores de que la Arquitectura 1 tiene menor dispersion y es mas estable, la tasa de falsos positivos es baja en ambos y casi que iguales por lo que son buenos modelos iniciales para un sistema de deteccion de intrusos.

En general se podria decir que ambos son similares pero la Arquitectura 1 presenta menos dispersion en los resultados y usa menos arboles para su modelo por lo que es mas eficiente y tiene un buen rendimiento. Esto a nivel general tambien nos dice que los RandomForests presentan buenos resultados con pocas modificaciones respecto a sus parametros, ya que en este caso solo se modificaron los n_estimators y se dejaron los valores defecto de scikit learn. Existe la posibilidad de que se pueda mejorar mas el rendimiento de ambos modelos con otros parametros optimizados.